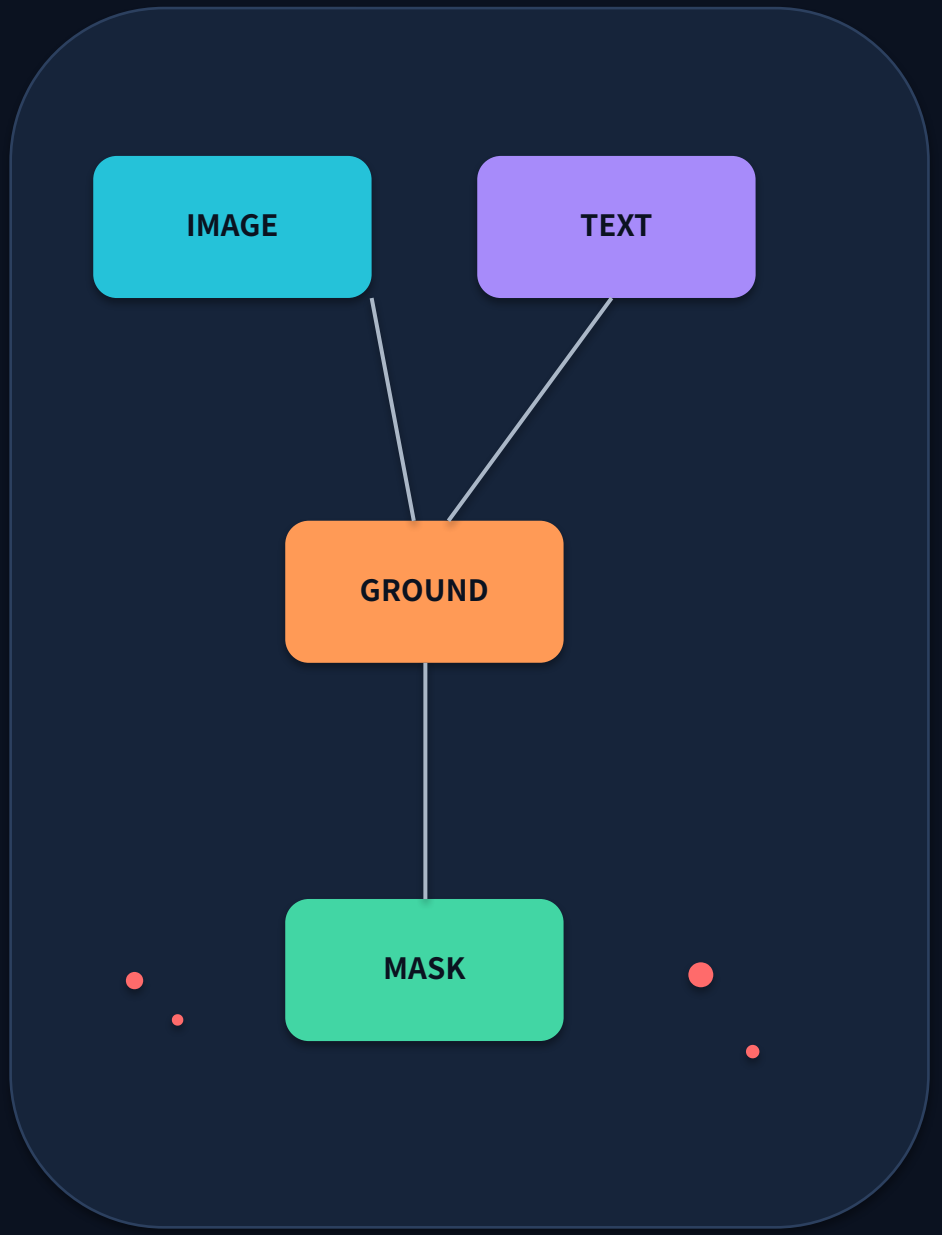
从视觉语言定位到工业异常分割

2026 研究趋势与 RIAS 论文精读

Referring Industrial Anomaly Segmentation
15 分钟组会报告

任务： RIAS　模型： DQFormer　数据： MVTec-Ref



2026.10 · 组会

先给结论：交叉方向最值得做，但要从“可靠性”切入

趋势

从“识别类别”走向有证据的定位 + 拒答

视觉语言的关键不再是说得长，而是定位准、目标不存在时不乱画。

01

论文

RIAS 首次把自然语言接入工业异常精细分割

贡献是任务、数据集与基线三件套；并不等于已证明真正开放集泛化。

02

选题

未见缺陷 × 复杂文本 × 小目标 × no-target

先构造可靠评测，再针对一个稳定失败模式改方法，范围适合研一推进。

03

一句话主线 用工业异常检测定义清晰任务，用视觉语言提供开放描述能力，用可靠性评测证明模型真的“看见”了。

依据： RIAS 原文 + 用户提供的 2026 文献检索对话（截至 2026-10-16）

研究主线：从异常分数，走向语言条件下的可靠分割

1

异常分数

正常数据建模
热力图 + 手工阈值

2

统一多类别

一个模型覆盖多产品
仍以二元异常为主

3

语言指代

按“哪种、哪里、什么属性”
直接输出像素掩码

4

可靠开放集

未见缺陷也能定位
找不到时正确拒答

RIAS 位于第 3 阶段

它建立了任务与数据，但第 4 阶段的“未见缺陷、反事实文本、跨域和校准拒答”仍是空白。

趋势判断：用户提供的 2026 文献调研； RIAS： Yue et al., arXiv:2602.03673v1

视觉语言：四个问题比“更大的模型”更关键

空间定位

复杂关系 / 小目标 / 遮挡

GroundingME · Ref-Adv

证据与幻觉

目标不存在时不应生成掩码

Counterfactual reasoning

开放词汇适配

少量参考图像弥补文本监督

Retrieve & Segment

效率

冻结主干、轻量适配、减少串联

RADSeg · adapter routes

代表工作来自用户提供的 2026 检索材料；本页强调研究问题，正式引用前需逐篇核验出版状态

工业异常检测：五条路线正在汇合

少 / 零样本、多类别

扩到新产品时不崩

AnoPLe · MoECLIP

01

语言引导分割

按描述输出精细掩码

RIAS

02

统一异常理解

检测 + 分割 + 分类 + 解释

GenAU · AD-Copilot

03

冻结基础模型

DINO/CLIP + 轻量适配器

PALADIN

04

真实场景与数据

合成缺陷、多视角、3D/ 视频

MIRAGE · MMVIAD

05

共同瓶颈 小缺陷 + 未见类别 + 文本扰动 + no-target 拒答 + 跨域泛化

路线图来自用户提供的 2026 检索材料；论文与数据集名称用于导航，不作未核验的性能结论

RIAS：把“异常检测”改写成“文本指代分割”

输入

图像 I + 描述 L

输出

掩码 M + 无异常标识 E

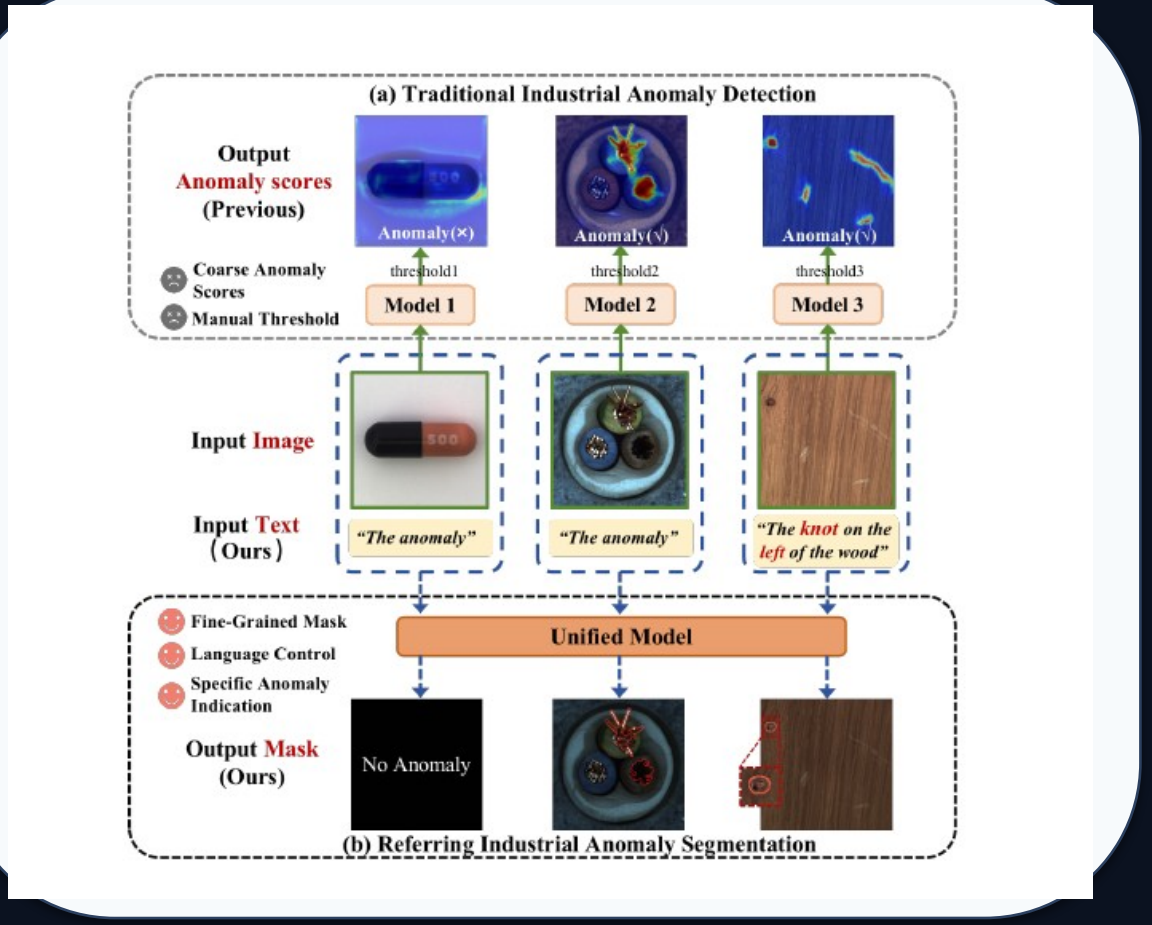
① 文本可指定缺陷类别、属性与位置

② 通用提示 “The anomaly” 可覆盖多种缺陷

③ E 判为 no-anomaly 时输出空掩码

任务范式： RIAS

基线模型： DQFormer



来源： Yue et al., Referring Industrial Anomaly Segmentation, Fig.1, arXiv:2602.03673v1 (2026)

MVTec-Ref： 2,110 个图像—文本—掩码三元组

1,224	384	502
Train	Val	Test

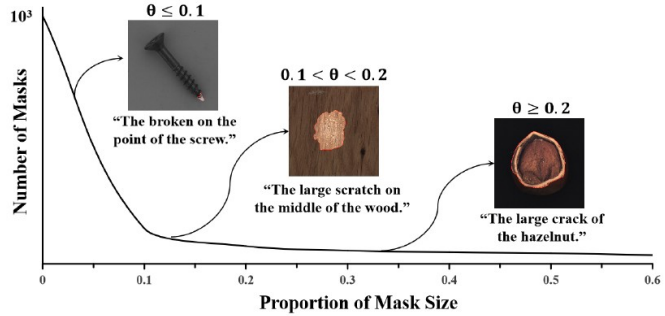
标注表达三类信息

类别 / 属性： red stain, hole

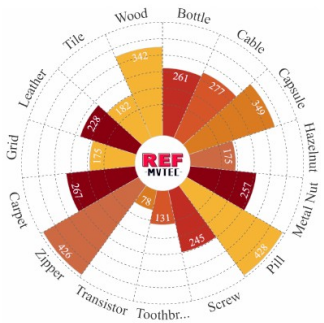
空间关系： left / middle / screw head

泛化提示： The anomaly

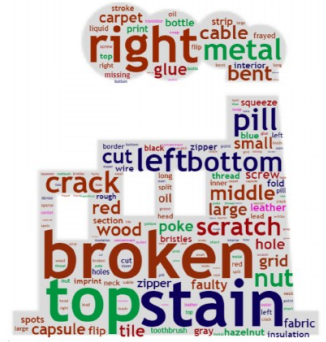
>90% 掩码面积 < 图像的 10%



(a) Anomaly mask size distribution.



(b) Object category distribution.



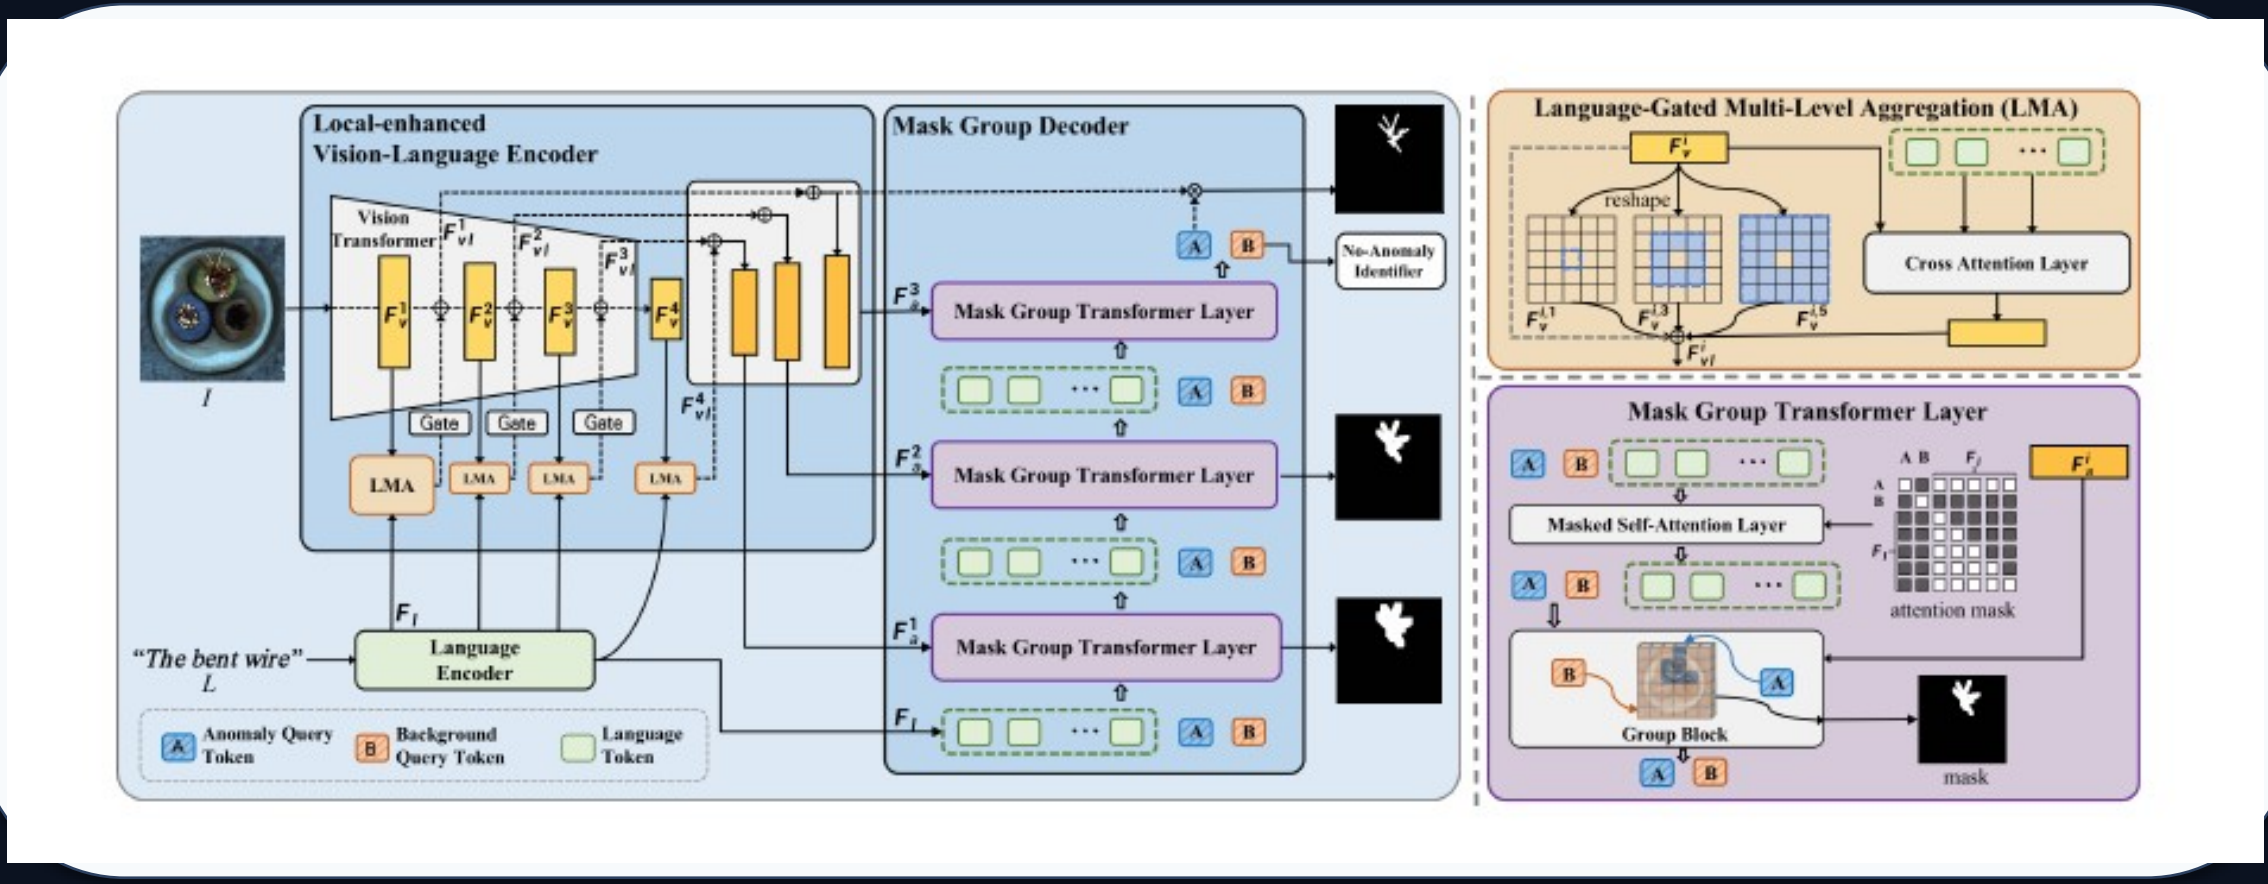
(c) Word cloud.

Fig. 2: Analysis of the dataset.

the model's generalization ability, preventing it from overfitting to specific cate-

来源： RIAS §3.2, §5.1 与 Appendix C；正文对小异常比例写法存在 90%/95% 差异，故此处采用“ >90%”

DQFormer： 多尺度视觉语言编码 + 双查询掩码解码



① Swin 四阶段特征

② LMA 局部多尺度增强

③ A / B 双查询交互

④ Mask + No-Anomaly

来源： RIAS Fig.3； 视觉主干 Swin Transformer， 语言特征通过 LMA 与 Mask Group Decoder 进入分割过程

两个关键设计：看清小缺陷，隔离语言与背景

LMA

局部多尺度 + 语言门控

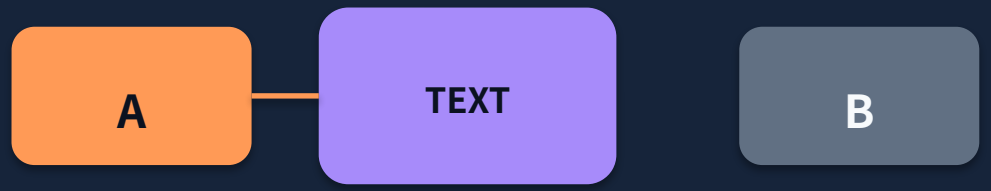


平均池化聚合邻域 → 与文本做交叉注意力 → 门控回注视觉主干

目标：兼顾微小纹理与跨尺度异常

Dual Query

Anomaly A / Background B



只有 A 读取语言； A/B 再共同对视觉像素分组。

目标：减少冗余 query，避免背景被文本污染

来源： RIAS §4.2–4.3； LMA 使用 r∈{1,3,5} 平均池化， Mask Group Transformer 使用 masked self-attention

主结果领先，但测试集增益的文字与表格不一致

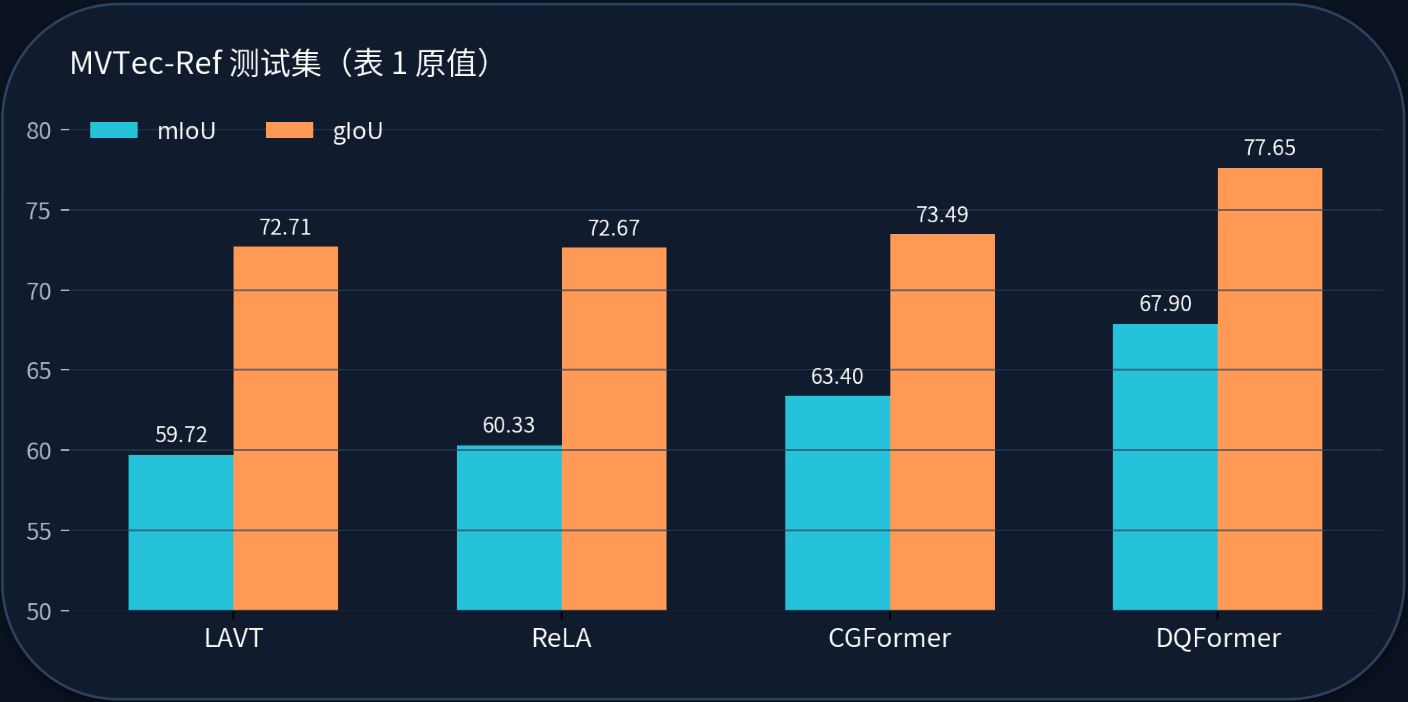


表 1 原值

DQFormer

67.90 mIoU

77.65 gIoU

对 CGFormer 的表格差值：
+4.50 mIoU / +4.16 gIoU

复核提醒 **摘要、正文和表 1 对测试集提升幅度给出不同数字；报告性能时建议引用表格原值，不引用文字增益。**

来源： RIAS Table 1； Val 差值 +3.08/+3.42 与正文一致， Test 差值与摘要 / 正文描述不一致

论文证明了什么？还有哪些结论不能直接推出？

已支持

- 统一模型覆盖 MVTec-Ref 多类别
- 文本条件下直接输出细粒度掩码
- Masked self-attn / Dual Query / LMA 均有消融收益
- 图像级 AUC 97.36，统一设置下有竞争力

尚未证明

- 严格留出“未见缺陷 / 未见产品”的开放集泛化
- 复杂、否定、错配文本下的稳健性与校准拒答
- 跨工厂 / 跨数据集 / 光照视角变化
- 代码与数据的可复现性：仓库当前仅写 coming soon

另一个信号：像素 AUC 93.13，低于 UniAD 的 96.90；语言分割优势尚未等价为传统像素异常定位优势。

来源：RIAS Tables 2–3；GitHub swagger-coder/RIAS-MVTec-Ref 于 2026-10-20 检查时 README 为“coming soon”

建议课题：面向未见缺陷的可靠文本条件异常分割

研究问题

同一模型能否在未见缺陷、复杂描述和 no-target 请求下，仍准确定位微小异常？

1

未见缺陷

严格 leave-defect-out

2

复杂文本

属性 / 空间 / 否定 / 同义改写

3

小目标

按 mask 面积分桶评测

4

正确拒答

描述不匹配时输出空掩码

5

跨域

产品 / 相机 / 光照变化

核心假设

正常参考图像 + 局部 / 全局一致性 + prompt consistency，可同时降低漏检与语言诱导误报。

研究设想：由 RIAS 尚未覆盖的失败模式推导；不属于原论文结论

最小可发表实验：先建立可信评测，再改一个失败模式

A

基线审计

复核数据划分与评测脚本
RIAS / CGFormer / CLIP 类基线

B

压力测试

文本改写、否定、错配
mask 面积分桶

C

开放集划分

leave-defect-out
leave-product-out / cross-domain

D

针对性方法

只解决一个稳定失败
消融 + 速度 + 可视化

指标 mIoU / gIoU + no-target FPR + prompt consistency + 小目标分桶 + 跨域性能下降

实际启动前置条件： MVTec-Ref 数据与代码正式公开；若仍未公开，先用公开 MVTec-AD 构造受控评测原型

带走三句话

01	**方向**	工业异常检测提供清晰任务；视觉语言提供开放描述、交互定位和可解释接口。
02	**论文**	RIAS 建立了文本指代工业异常分割，但“真正开放集”和可靠拒答仍未被充分验证。
03	**下一步**	优先做未见缺陷 × 复杂文本 × 小目标 × no-target 的评测与针对性改进。

建议讨论：先做“语言稳健性评测”还是“未见类别泛化”？

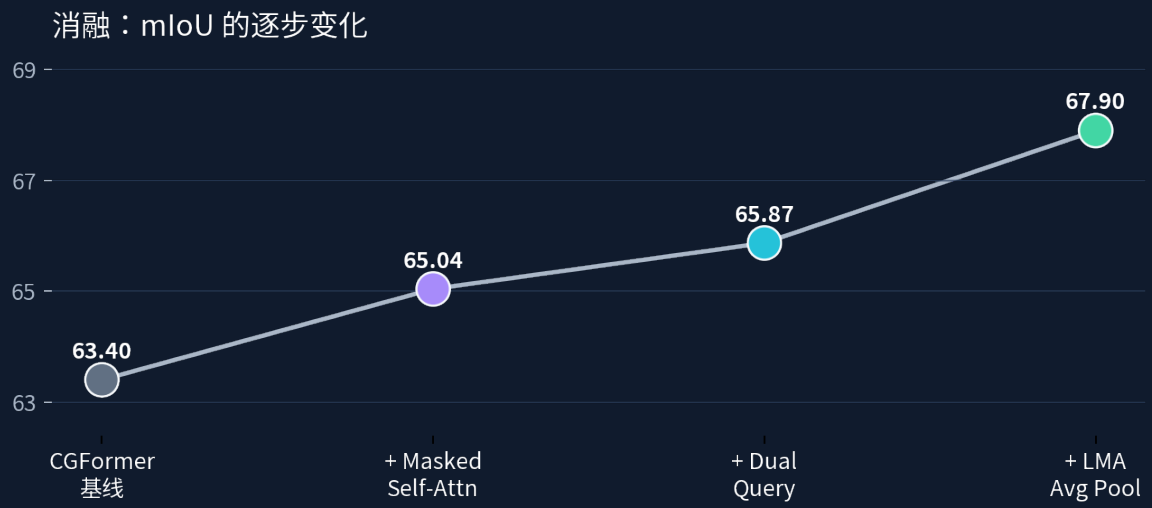
2026 候选阅读图谱：按研究问题选，不按榜单追

问题	代表工作	阅读时要回答	优先级
语言指代分割	**RIAS**	**任务 / 数据 / 像素掩码**	**最高**
统一异常理解	GenAU · AD-Copilot	解释能力 vs 分割精度	高
复杂表达评测	Ref-Adv · KnowDR-REC	否定、关系、负样本	高
提示学习	AnoPLe · MoECLIP	少 / 零样本、多类别泛化	中
轻量跨模态	PALADIN · RADSeg	冻结主干与效率	中
真实场景扩展	Real-IAD Variety · MMVIAD	跨行业、多视角 / 视频	中

注：除 RIAS 外，本表来源于用户提供的检索对话；正式引用与复现前应核验论文版本、开放状态和代码。

检索材料截止 2026-10-16

消融与传统 IAD 对比：两个容易忽略的细节



传统 IAD 对比（Test）

方法	Image-AUC	Pixel-AUC
JNLD	91.30	88.60
DRAEM	89.76	88.24
UniAD	96.57	96.90
DQFormer	**97.36**	**93.13**

解读 LMA 带来最大 mIoU 增益；DQFormer 图像级最好，但像素 AUC 仍落后 UniAD 3.77 点。

来源：RIAS Tables 2–3；消融顺序按论文表格重绘